电商用户行为与人群分层分析

UCI Online Retail II 数据集 | 分析者：张仲慈 | 2026 年 10 月

项目概述

基于一家英国跨境电商 2009–2011 两年的真实交易数据，完成**数据清洗 → 探索性分析 → RFM 人群分层**全流程，输出可供推广投放圈选使用的客户分群明细。目标是通过量化方法识别核心客户、定位增长机会，为差异化运营提供决策依据。

数据概况

原始交易	1,067,371 行	**时间跨度**	2009-12 → 2011-12（2 年）
清洗后	779,425 行（保留 73%）	**覆盖国家**	40+（UK 占 82.82%）
唯一客户	5,878	**唯一订单**	36,969

清洗策略：剔除缺失 Customer ID（22.8%）、退款单（Invoice 以 C 开头，1.83%）、异常价格（Price ≤ 0）、Quantity ≤ 0 的记录及完全重复行。衍生订单金额 `TotalPrice = Quantity × Price` 及时间维度字段。

关键业务洞察

- **销售节律：**10–11 月为旺季高峰（吻合圣诞礼品批发备货周期），TOP3 月份为 2010-11、2011-10、2011-11
- **市场结构：**UK 本土贡献 82.82%，海外 TOP5 为 EIRE、Germany、France、Netherlands、Spain，是明显的”本土为主、欧洲 B2B”业态
- **运营特征：**周六订单量近零，典型 B2B 工作日作息；下单高峰集中在工作日 10:00–15:00
- **客户结构：**一次性客户占 27.6%，复购运营是关键增长点；**Top 20% 客户贡献 77.23% 销售额**，经典二八法则在该数据上成立

RFM 分层结果

对 5,878 位客户按 Recency / Frequency / Monetary 五分位打分（1–5），依组合规则划分为五群。核心对比：

群组	客户数	客户占比	销售额占比	人均消费（£）	运营建议
高价值	1,297	22.1%	**68.3%**	7,964	核心金主，重点维护与增值
沉睡	1,955	33.3%	23.5%	1,820	**召回 ROI 最高**，重点触达
潜力	1,067	18.2%	6.0%	850	培育升级为高价值
流失	1,280	21.8%	1.9%	221	低成本唤醒或放弃
其他	279	4.7%	0.5%	275	常规维系

注：人均消费为示意值，以实际 *CSV* 为准。

核心结论：高价值与流失群客户数相当（均约 22%），但**销售额贡献相差约 36 倍**，差异化运营策略可带来显著 ROI 提升；沉睡群贡献 23.5% 销售额却接近非活跃状态，为召回触达的最高优先级。

方法与工具

分析流程：pandas 完成数据读取 / 清洗 / 聚合；matplotlib + seaborn 产出 8 张可视化（月度趋势、国家分布、时段模式、客户分布、人群对比、R–F 热力图）；按业务规则定义分群逻辑，产出 `customer_segments.csv` 作为交付物。

工具栈：Python 3.11、pandas、numpy、matplotlib、seaborn、Jupyter Lab；venv 管理项目依赖。

局限与下一步

- RFM 为时点快照，未覆盖客户动态迁移；下一步可加入分群稳定性验证（滑动快照窗口）
- 规则法分群简洁易解释，但在边界样本上不如 KMeans 等聚类灵活；可对比两种方法的业务一致性
- 建模侧可延展为客户生命周期价值（CLV）预测与升级概率模型，支撑更前瞻的运营决策

数据来源：UCI Machine Learning Repository, Online Retail II（https://archive.ics.uci.edu/dataset/502/online+retail+ii） 项目代码与可视化：详见项目仓库 `README.md`